

prova_de_estatística_1

August 21, 2021

1 Problema

1- Escolha aleatoriamente 50 números e utilizando a fórmula $[k=1+(3,32*\log N)+\ln N]$ para o número de classes construa uma distribuição de frequência. OBS. COMO OS NÚMEROS SÃO ALEATÓRIOS NÃO PODERÁ TER PROVAS IGUAIS, CASO ISSO OCORRA AS DUAS SERÃO ZERADAS (2,0 pontos)

2- Calcule a média aritmética da distribuição que você criou na questão 1; (2,0 pontos)

3- Calcule a Mediana da distribuição criada acima (2,0 pontos)

4- Calcule o 1º e 3º quartil da distribuição acima (2,0 pontos)

5- Com os números que você escolheu construa um Boxplot. (2,0 pontos)

2 Import

```
[178]: import scipy.stats          #importando a biblioteca scipy
import math          #importando a biblioteca math
import random        #importando a biblioteca random
import numpy as np    #importando a biblioteca numpy
import pandas as pd   #importando a biblioteca pandas
import matplotlib.pyplot as plt #importando a biblioteca matplotlib
```

2.1 1.1 - Escolhendo 50 números aleatórios entre 1 e 500

```
[179]: amostra = np.random.randint(1,500,(1,50))
```

```
[180]: amostra = amostra[0]
```

```
[181]: amostra = amostra.tolist()
```

```
[228]: amostra = sorted(amostra) # Ordenando valores sorteados
```

```
[229]: amostra
```

```
[229]: [27,
       32,
       73,
```

89,
95,
110,
121,
132,
145,
147,
149,
151,
153,
155,
160,
176,
178,
185,
190,
218,
219,
219,
223,
243,
257,
260,
261,
264,
284,
288,
288,
289,
290,
292,
326,
332,
336,
337,
346,
352,
370,
373,
381,
388,
418,
423,
423,
429,
477,
477]

2.2 1.2 - Distribuição de frequência

```
[183]: df = pd.DataFrame(np.array(amostra).reshape(50,1), columns = list("A")) #  
      ↪ Transformando lista em pandas dataframe
```

```
[184]: df.head() # visualizando os 5 primeiros dados da tabela
```

```
[184]: A  
0  27  
1  32  
2  73  
3  89  
4  95
```

```
[185]: df = df.sort_values(by = "A", ascending=True) # organizando os elementos da  
      ↪ coluna única "A"
```

```
[186]: df['fi'] = '-'
```

2.3 1.3 - Número de classes

```
[187]: # fórmula  $k = 1 + (3,32 * \log N) + \ln N$   
  
k = 1 + (3.32 * math.log10(50)) + np.log(50)
```

```
[188]: k
```

```
[188]: 10.552603419823727
```

```
[189]: k = round(k) #arredondando
```

```
[190]: k
```

```
[190]: 11
```

2.4 1.4 - Distribuição de frequências

```
[191]: # Amplitude dos dados = Valor maior dos registros - menor valor  
at = df['A'].max() - df['A'].min()
```

```
[192]: at
```

```
[192]: 450
```

```
[193]: # Amplitude dos intervalos  
  
ai = at/k
```

```
[194]: ai = math.ceil(ai) # Arredondamento para cima
ai
```

```
[194]: 41
```

```
[195]: amplitudeintervalostxt = []
# Menor valor da série
menor = round(df['A'].min(),1)

# Menor valor somado a amplitude
menor_amp = round(menor+ai,1)

valor = menor

while valor < df['A'].max():
    amplitudeintervalostxt.append('{} - {}'.
    ↳format(round(valor,1),round(valor+ai,1)))
    valor = valor + ai
```

```
[196]: amplitudeintervalostxt
```

```
[196]: ['27 - 68',
'68 - 109',
'109 - 150',
'150 - 191',
'191 - 232',
'232 - 273',
'273 - 314',
'314 - 355',
'355 - 396',
'396 - 437',
'437 - 478']
```

```
[197]: amplitudeintervaloslist = []
intervalo = []

primeirotermo = round(df['A'].min(),1)
segundotermo = primeirotermo + ai
intervalo.append(primeirotermo)
intervalo.append(segundotermo)
amplitudeintervaloslist.append(intervalo)

for i in range(len(amplitudeintervalostxt) - 1):
    amplitudeintervaloslist.append([])
    amplitudeintervaloslist[i+1].append(amplitudeintervaloslist[i][-1])
    amplitudeintervaloslist[i+1].append(amplitudeintervaloslist[i][-1]+ai)
```

```
[198]: amplitudeintervaloslist
```

```
[198]: [[27, 68],  
        [68, 109],  
        [109, 150],  
        [150, 191],  
        [191, 232],  
        [232, 273],  
        [273, 314],  
        [314, 355],  
        [355, 396],  
        [396, 437],  
        [437, 478]]
```

```
[199]: amplitudeintervalostxt = np.array(amplitudeintervalostxt)
```

```
[200]: df2 = pd.DataFrame(amplitudeintervalostxt, columns=['amplitude_intervalos'])
```

```
[201]: df2
```

```
[201]:      amplitude_intervalos  
0           27 - 68  
1           68 - 109  
2          109 - 150  
3          150 - 191  
4          191 - 232  
5          232 - 273  
6          273 - 314  
7          314 - 355  
8          355 - 396  
9          396 - 437  
10         437 - 478
```

```
[202]: provasnointervalolist = [[]]  
copiaamostra = amostra[:]  
  
end = False  
  
for j in range(len(amplitudeintervaloslist)):  
    while copiaamostra[0] < amplitudeintervaloslist[j][-1] and end == False:  
        provasnointervalolist[j].append(copiaamostra[0])  
        if len(copiaamostra) > 1:  
            del copiaamostra[0]  
        elif len(copiaamostra) == 1:  
            end = True  
    else:  
        provasnointervalolist.append([])
```

```

if end == True:
    del provasnointervalolist[-1]

```

```
[203]: provasnointervalolist
```

```

[203]: [[27, 32],
        [73, 89, 95],
        [110, 121, 132, 145, 147, 149],
        [151, 153, 155, 160, 176, 178, 185, 190],
        [218, 219, 219, 223],
        [243, 257, 260, 261, 264],
        [284, 288, 288, 289, 290, 292],
        [326, 332, 336, 337, 346, 352],
        [370, 373, 381, 388],
        [418, 423, 423, 429],
        [477, 477]]

```

```
[204]: df2['provas_intervalo'] = provasnointervalolist
```

```
[205]: df2
```

```

[205]:   amplitude_intervalos      provas_intervalo
0           27 - 68           [27, 32]
1           68 - 109           [73, 89, 95]
2          109 - 150      [110, 121, 132, 145, 147, 149]
3          150 - 191  [151, 153, 155, 160, 176, 178, 185, 190]
4          191 - 232           [218, 219, 219, 223]
5          232 - 273           [243, 257, 260, 261, 264]
6          273 - 314      [284, 288, 288, 289, 290, 292]
7          314 - 355      [326, 332, 336, 337, 346, 352]
8          355 - 396           [370, 373, 381, 388]
9          396 - 437           [418, 423, 423, 429]
10         437 - 478           [477, 477]

```

```
[206]: df2['frequencia_absoluta'] = df2['provas_intervalo'].map(lambda x : len(x))
```

```
[207]: df2
```

```

[207]:   amplitude_intervalos      provas_intervalo \
0           27 - 68           [27, 32]
1           68 - 109           [73, 89, 95]
2          109 - 150      [110, 121, 132, 145, 147, 149]
3          150 - 191  [151, 153, 155, 160, 176, 178, 185, 190]
4          191 - 232           [218, 219, 219, 223]
5          232 - 273           [243, 257, 260, 261, 264]
6          273 - 314      [284, 288, 288, 289, 290, 292]
7          314 - 355      [326, 332, 336, 337, 346, 352]
8          355 - 396           [370, 373, 381, 388]

```

9	396 - 437	[418, 423, 423, 429]
10	437 - 478	[477, 477]

	frequencia_absoluta
0	2
1	3
2	6
3	8
4	4
5	5
6	6
7	6
8	4
9	4
10	2

```
[208]: df2 = df2.assign(frequencia_acumulada=df2.frequencia_absoluta.cumsum())
```

```
[209]: df2['frequencia_relativa'] = df2['frequencia_absoluta'].map(lambda x: (x/
↳ len(amostra))*100)
```

```
[210]: df2
```

```
[210]:
```

	amplitude_intervalos	provas_intervalo \
0	27 - 68	[27, 32]
1	68 - 109	[73, 89, 95]
2	109 - 150	[110, 121, 132, 145, 147, 149]
3	150 - 191	[151, 153, 155, 160, 176, 178, 185, 190]
4	191 - 232	[218, 219, 219, 223]
5	232 - 273	[243, 257, 260, 261, 264]
6	273 - 314	[284, 288, 288, 289, 290, 292]
7	314 - 355	[326, 332, 336, 337, 346, 352]
8	355 - 396	[370, 373, 381, 388]
9	396 - 437	[418, 423, 423, 429]
10	437 - 478	[477, 477]

	frequencia_absoluta	frequencia_acumulada	frequencia_relativa
0	2	2	4.0
1	3	5	6.0
2	6	11	12.0
3	8	19	16.0
4	4	23	8.0
5	5	28	10.0
6	6	34	12.0
7	6	40	12.0
8	4	44	8.0
9	4	48	8.0

10	2	50	4.0
----	---	----	-----

```
[211]: df2 = df2.assign(frequencia_relativa_acumulada=df2.frequencia_relativa.cumsum())
```

```
[212]: df2
```

```
[212]:
```

	amplitude_intervalos	provas_intervalo \
0	27 - 68	[27, 32]
1	68 - 109	[73, 89, 95]
2	109 - 150	[110, 121, 132, 145, 147, 149]
3	150 - 191	[151, 153, 155, 160, 176, 178, 185, 190]
4	191 - 232	[218, 219, 219, 223]
5	232 - 273	[243, 257, 260, 261, 264]
6	273 - 314	[284, 288, 288, 289, 290, 292]
7	314 - 355	[326, 332, 336, 337, 346, 352]
8	355 - 396	[370, 373, 381, 388]
9	396 - 437	[418, 423, 423, 429]
10	437 - 478	[477, 477]

	frequencia_absoluta	frequencia_acumulada	frequencia_relativa \
0	2	2	4.0
1	3	5	6.0
2	6	11	12.0
3	8	19	16.0
4	4	23	8.0
5	5	28	10.0
6	6	34	12.0
7	6	40	12.0
8	4	44	8.0
9	4	48	8.0
10	2	50	4.0

	frequencia_relativa_acumulada
0	4.0
1	10.0
2	22.0
3	38.0
4	46.0
5	56.0
6	68.0
7	80.0
8	88.0
9	96.0
10	100.0

3 2 - Calculando a média aritmética

```
[213]: media = np.mean(amostra)
```

```
[214]: media
```

```
[214]: 251.02
```

4 3 - Achando a mediana

```
[215]: mediana = np.median(amostra)
```

```
[216]: mediana
```

```
[216]: 258.5
```

5 4 - Calculando o primeiro e o terceiro quartil

```
[218]: q1 = np.percentile(df.A, 25)
```

```
[219]: q1 # primeiro quartil
```

```
[219]: 153.5
```

```
[220]: median = np.percentile(df.A, 50)
```

```
[221]: median
```

```
[221]: 258.5
```


```
[222]: q2 = np.percentile(df.A, 75)
```

```
[223]: q2 # terceiro quartil
```

```
[223]: 336.75
```

6 5 - Construindo boxplot com valores

```
[227]: boxplot = df.boxplot()
```



[]: